

Matheus Monteiro Alves Melo

**Um Modelo de Sobrevivência em Tempo
Discreto com Fração de Cura Baseado em
Riscos Competitivos Latentes**

Vitória - ES

2025

Matheus Monteiro Alves Melo

**Um Modelo de Sobrevivência em Tempo Discreto com
Fração de Cura Baseado em Riscos Competitivos
Latentes**

Monografia apresentada à Universidade Federal do Espírito Santo como parte das exigências para a aprovação na disciplina Trabalho de Conclusão de Curso II

UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO

Orientador: Prof. Dr. Patrick Borges

Vitória - ES

2025

Matheus Monteiro Alves Melo

Um Modelo de Sobrevivência em Tempo Discreto com Fração de Cura
Baseado em Riscos Competitivos Latentes

Monografia apresentada à Universidade Federal do Espírito Santo como parte das exigências para a aprovação na disciplina Trabalho de Conclusão de Curso II

Aprovado em: ____/____/____

BANCA EXAMINADORA

Prof. Dr. Patrick Borges
Universidade Federal do Espírito Santo

Profa. Dra. ...
Universidade Federal do Espírito Santo

Prof. Dr. ...
Universidade Federal do Espírito Santo

AGRADECIMENTOS

O desenvolvimento desse TCC foi consequência de não só dois semestres de trabalho, mas também de 4 anos de faculdade, dessa forma, gostaria de agradecer a todos que encontrei durante esses anos. Em especial, agradeço ao professor Patrick pela orientação nesses dois períodos e a minha família por todo apoio.

RESUMO

Em estudos de sobrevivência, é comum a presença de indivíduos que não experimentam o evento de interesse após um longo período de acompanhamento, configurando a chamada fração de cura. Além disso, em aplicações biomédicas, os tempos de sobrevivência são frequentemente observados em unidades discretas e inteiras, como dias, semanas ou meses, o que motiva o uso de modelos formulados diretamente nessa escala temporal. Neste trabalho, propõe-se um modelo de sobrevivência com fração de cura em tempo discreto baseado em riscos competitivos latentes. Assume-se que cada indivíduo possui um número latente de causas potenciais para a ocorrência do evento, sendo considerado curado quando esse número é nulo. O número de riscos latentes é modelado por uma distribuição Binomial Negativa, permitindo capturar heterogeneidade não observada entre indivíduos, enquanto os tempos de ativação associados a cada risco seguem uma distribuição Lognormal Discreta, proposta como alternativa às distribuições discretas mais usuais em análise de sobrevivência em tempo discreto, como aquelas baseadas na Weibull discreta, oferecendo maior flexibilidade na descrição de diferentes padrões de risco. A inferência estatística é conduzida via máxima verossimilhança, considerando censura à direita. O desempenho do modelo é avaliado por meio de um estudo de simulação de Monte Carlo sob diferentes cenários de tamanho amostral e níveis de censura. Por fim, o modelo é aplicado a um conjunto de dados reais de pacientes com infarto agudo do miocárdio, ilustrando sua aplicabilidade e interpretabilidade em contextos clínicos com tempos de sobrevivência naturalmente discretos.

Palavras-chave: Análise de sobrevivência em tempo discreto; Modelo de fração de cura; Distribuição binomial negativa; Riscos competitivos latentes; Distribuição Lognormal Discreta; Modelos de Regressão; Estimação por máxima verossimilhança; Simulação de Monte Carlo.

ABSTRACT

In survival studies, it is common to find individuals who do not experience the event of interest after a long period of submission, forming the so-called cure fraction. Furthermore, in biomedical applications, survival times are often observed in whole and discrete units, such as days, weeks, or months, which motivates the use of models formulated directly on this time scale. This work proposes a discrete-time survival model with a cure fraction based on latent competing risks. It is assumed that each individual has a latent number of potential causes for the event occurrence, and they are considered cured when this number is zero. The number of latent risks is modeled by a Negative Binomial distribution, allowing for the capture of unobserved heterogeneity among individuals, while the activation times associated with each risk follow a Discrete Lognormal distribution, proposed as an alternative to the more commonly used discrete distributions in discrete-time survival analysis, such as those based on the discrete Weibull, offering greater flexibility in describing different hazard patterns. Statistical inference is performed via maximum likelihood, considering right censoring. The model's performance is evaluated through a Monte Carlo simulation study under different sample size and censoring level scenarios. Finally, the model is applied to a real-world dataset of patients with acute myocardial infarction, illustrating its applicability and interpretability in clinical contexts with naturally discrete survival times.

Keywords: Discrete-time survival analysis; Cure fraction model; Negative binomial distribution; Latent competing risks; Discrete Lognormal distribution; Regression models; Maximum likelihood estimation; Monte Carlo simulation.

LISTA DE ILUSTRAÇÕES

Figura 1 – Curvas de Kaplan-Meier (linhas) e de sobrevivência ajustada pelo modelo (pontos)	25
Figura 2 – Envelope Simulado	26
Figura 3 – Resultados da tabela 8.	31
Figura 4 – Resultados da tabela 9.	32
Figura 5 – Resultados da tabela 10.	33
Figura 6 – Resultados da tabela 11.	34

LISTA DE TABELAS

Tabela 1 – Descrição das variáveis do banco de dados <code>infarto.dat</code>	23
Tabela 2 – Distribuição de censura e eventos por grupo de covariáveis	23
Tabela 3 – Teste de Log-Rank por grupos de idade e sexo	24
Tabela 4 – Estimativas de máxima verossimilhança dos coeficientes e significância estatística (95 %) via teste t	25
Tabela 5 – Estimativas da Fração de Cura (p_0), Variância e Intervalos de Confiança de 95%	26
Tabela 6 – Valores fixados dos parâmetros no Cenário 1 da simulação	29
Tabela 7 – Valores fixados dos parâmetros no Cenário 2 da simulação	30
Tabela 8 – Valor Real, vício, RMSE, AW e CP para $P_{\text{susc}} = 0.05$ ($R = 1000$)	41
Tabela 9 – Valor Real, vício, RMSE, AW e CP para $P_{\text{susc}} = 0.05$ ($R = 1000$)	42
Tabela 10 – Valor Real, vício, RMSE, AW e CP para $P_{\text{susc}} = 0.10$ ($R = 1000$)	43
Tabela 11 – Valor Real, vício, RMSE, AW e CP para $P_{\text{susc}} = 0.15$ ($R = 1000$)	44

LISTA DE SÍMBOLOS

α	Letra grega minúscula Alfa
η	Letra grega minúscula Eta
β	Letra grega minúscula Beta
θ	Letra grega minúscula Teta
δ	Letra grega minúscula Delta
τ	Letra grega Tau
ϕ	Letra grega minúscula Fi
Φ	Letra grega maiúscula Fi
σ	Letra grega minúscula Sigma
μ	Letra grega minúscula Mi
∞	Infinito
$\in$	Pertence

SUMÁRIO

1	INTRODUÇÃO	11
1.1	JUSTIFICATIVA	12
1.1.1	Objetivos	13
1.1.2	Objetivo Geral	13
1.1.3	Objetivos Específicos	13
2	Desenvolvimento	14
2.1	Fração de Cura	14
2.2	Riscos Competitivos Latentes	14
2.3	Modelo Binomial Negativo com Fração de Cura e Riscos Competitivos Latentes	15
2.3.1	Distribuição do Número de Causas Latentes	15
2.3.2	Função de Sobrevida Populacional	16
2.3.3	Fração de Cura e Interpretação dos Parâmetros	17
2.4	Distribuição Lognormal Discreta	17
2.5	Modelo de Regressão	19
2.6	Estimação dos Parâmetros por Máxima Verossimilhança	20
3	RESULTADOS E DISCUSSÕES	22
3.1	Aplicação	22
3.1.1	Descrição dos dados	22
3.1.2	Especificação do modelo	23
3.1.3	Análise de ajuste e resultados	24
3.2	Simulação	27
3.2.1	Cenários de Simulação	29
3.2.2	Análise das Propriedades dos Estimadores	30
3.2.3	Resultados da simulação (Cenário 1)	31
3.2.4	Resultados da simulação (Cenário 2)	31
4	CONCLUSÃO	35
	Referências	37
	APÊNDICE A Cenário 1	41
	APÊNDICE B Cenário 2	42

APÊNDICE C Cenário 2 43

APÊNDICE D Cenário 2 44

1 INTRODUÇÃO

A análise de sobrevivência constitui uma área da estatística fundamental para investigar o tempo até a ocorrência de eventos de interesse em áreas como Medicina, Epidemiologia e Ciências Sociais (COLLETT, 2003; KLEIN; MOESCHBERGER, 2003). Modelos clássicos, tanto paramétricos (exponencial, Weibull, lognormal) quanto semiparamétricos em Cox (1972), partem do pressuposto de que todos os indivíduos da população são suscetíveis ao evento. Contudo, em vários contextos clínicos contemporâneos, parte dos indivíduos nunca manifesta o evento-alvo, mesmo sob acompanhamento prolongado, devido a avanços terapêuticos e intervenções efetivas (SPOLVERATO et al., 2017). Ignorar essa subpopulação imune ou curada pode levar a estimativas viesadas e a interpretações equivocadas sobre prognóstico e eficácia de tratamentos.

Para lidar com essa estrutura populacional, foram desenvolvidos os modelos de fração de cura, que explicitamente distinguem entre indivíduos suscetíveis ao evento de interesse e indivíduos curados (MALLER; ZHOU, 1996). Dentre essas formulações, os modelos baseados em riscos competitivos latentes apresentados em Yakovlev e Tsodikov (1996) oferecem uma interpretação mecanística atraente: o tempo até o evento observado corresponde à primeira ocorrência entre múltiplas causas latentes de falha. Essa abordagem permite incorporar heterogeneidade não observada entre os indivíduos modelando o número de causas latentes por meio de distribuições de contagem, como Poisson, Binomial Negativa ou COM-Poisson usadas em trabalhos como Rodrigues et al. (2011), Pal e Balakrishnan (2016), Balakrishnan e Feng (2018), conferindo maior flexibilidade e plausibilidade biológica.

Paralelamente, a escala temporal dos dados merece atenção especial. Apesar da predominância de modelos contínuos na literatura, muitos registros clínicos são naturalmente discretos e coletados em unidades inteiras (dias, semanas, meses). A aplicação de modelos contínuos a tais dados pode introduzir distorções (NAKANO; CARRASCO, 2006), justificando o interesse crescente em modelos formulados diretamente em tempo discreto como Allison (1982), Singer e Willett (1993), Beyersmann (2018). Nesse contexto, distribuições como a Weibull discreta de Nakagawa e Osaki (1975) têm sido empregadas com sucesso em aplicações biomédicas em trabalhos como Silva (2015), Brunello e Nakano (2015), Oliveira, Cancho e Louzada (2019).

Visando ampliar a flexibilidade na modelagem de tempos discretos, a distribuição log-normal discreta de Lyu e Nadarajah (2022) emerge como uma alternativa promissora. Sua ver-

são contínua possui ampla tradição em análise de sobrevivência e já foi integrada a modelos de fração de cura como em Taweab, Al-Moisheer e Al-Moisheer (2012), fornecendo base teórica sólida para sua adoção em estruturas de riscos competitivos. No domínio discreto, seus parâmetros preservam interpretação direta e facilitam a incorporação de covariáveis, apresentando-se como uma opção atrativa frente a formulações baseadas na Weibull discreta presentes em Oliveira, Cancho e Louzada (2019), Brunello e Nakano (2015), Achcar et al. (2021), Silva, Otiniano e Nakano (2019).

Diante desse panorama, este trabalho propõe um modelo de fração de cura formulado inteiramente em tempo discreto e estruturado por riscos competitivos latentes. Suas contribuições principais articulam-se na combinação de três eixos, explorados de maneira isolada nos artigos citados anteriormente (utilizando outras distribuições para os riscos competitivos e tempos latentes). São eles: (i) a adoção de uma estrutura temporal discreta que respeita a granularidade comum dos dados clínicos; (ii) a modelagem da heterogeneidade não observada via distribuição Binomial Negativa para o número de riscos latentes; e (iii) a utilização da distribuição lognormal discreta para os tempos de ativação desses riscos, ampliando o espectro de padrões de risco capturáveis.

A estimação dos parâmetros é realizada por máxima verossimilhança. Um estudo de simulação Monte Carlo é desenvolvido para avaliar o desempenho inferencial do modelo sob diferentes cenários de censura e tamanhos amostrais. Por fim, o modelo é aplicado a um conjunto de dados reais de pacientes que morreram devido ao infarto agudo do miocárdio, inovando ao demonstrar sua utilidade prática na identificação das covariáveis relacionadas à fração de cura (representada por indivíduos que não falaceram após um longo período de acompanhamento depois de terem o infarto do miocárdio) e na interpretabilidade dos parâmetros e dos riscos competitivos em tal contexto.

1.1 JUSTIFICATIVA

Conforme destacado na introdução, a modelagem em tempo discreto oferece vantagens interpretativas e de aderência aos dados clínicos. Em contraste com a abordagem predominante na literatura de modelos de fração de cura, que usualmente emprega distribuições contínuas para os tempos de ativação latentes, como a Weibull, este estudo propõe uma formulação inteiramente em tempo discreto. Assume-se que os tempos de ativação são variáveis aleatórias discretas, independentes e identicamente distribuídas segundo a distribuição lognormal discreta,

preservando a natureza dos dados observados e ampliando a flexibilidade na modelagem dos padrões de risco.

1.1.1 OBJETIVOS

1.1.2 OBJETIVO GERAL

Propor e desenvolver um modelo de fração de cura formulado em tempo discreto com riscos competitivos latentes, no qual o número de causas de falha segue uma distribuição Binomial Negativa, permitindo acomodar superdispersão, e os tempos de ativação de cada causa latente seguem a distribuição lognormal discreta.

1.1.3 OBJETIVOS ESPECÍFICOS

- Desenvolver a formulação probabilística do modelo de fração de cura em tempo discreto com riscos competitivos latentes, incorporando a distribuição Binomial Negativa para o número de causas e a distribuição lognormal discreta para os tempos latentes.
- Derivar a função de verossimilhança e implementar o procedimento de estimação por máxima verossimilhança para os parâmetros do modelo, incluindo, quando aplicável, efeitos de covariáveis.
- Avaliar o desempenho inferencial dos estimadores de máxima verossimilhança por meio de um estudo de simulação de Monte Carlo, considerando diferentes tamanhos amostrais e níveis de censura à direita.
- Aplicar o modelo proposto a um conjunto de dados reais com tempos de sobrevivência discretos, ilustrando a interpretação da fração de cura, da heterogeneidade não observada e dos mecanismos de risco no contexto do infarto agudo do miocárdio.

2 DESENVOLVIMENTO

2.1 FRAÇÃO DE CURA

Em diversos estudos de sobrevivência observa-se que uma parcela da população nunca experimenta o evento de interesse, mesmo após longos períodos de acompanhamento. Esse comportamento caracteriza a presença de uma fração de cura, fenômeno amplamente documentado em aplicações biomédicas, epidemiológicas e de confiabilidade como Balakrishnan e Barui (2021). Nesses contextos, a população é naturalmente composta por dois subgrupos distintos: indivíduos suscetíveis ao evento e indivíduos curados (ou imunes).

A modelagem estatística dessa estrutura populacional foi introduzida inicialmente por Boag (1949) e formalizada por Berkson e Gage (1952) por meio dos modelos de mistura com fração de cura. Primeiramente, considere a função de sobrevivência da população total, denotada por $S_{\text{pop}}(y)$. Ela representa a probabilidade de um indivíduo não apresentar o evento até o tempo y . Ela é definida como:

$$S_{\text{pop}}(y) = p_0 + (1 - p_0)S(y), \quad (2.1)$$

onde $S(y)$ é a função de sobrevida dos indivíduos suscetíveis ao evento de interesse e p_0 a fração de cura. Dessa maneira, temos que o limite assintótico dessa função é dada por:

$$p_0 = \lim_{y \rightarrow \infty} S_{\text{pop}}(y), \quad (2.2)$$

representando a proporção de indivíduos que não vão apresentar o evento de interesse.

2.2 RISCOS COMPETITIVOS LATENTES

Para modelar explicitamente os mecanismos não observáveis associados à ocorrência do evento, adota-se a abordagem de riscos competitivos latentes, presente em artigos como Tsodikov, Ibrahim e Yakovlev (2003), Cancho, Rodrigues e Castro (2011). Nessa formulação, assume-se que o tempo até a falha observável resulta da ativação do primeiro entre vários riscos potenciais latentes.

Formalmente, seja M uma variável aleatória discreta não observável que representa o número de causas latentes associadas a um indivíduo. Caso $M = 0$, o indivíduo é considerado

curado. Para cada uma das M causas ativas, define-se uma variável aleatória $W_i, i = 1, \dots, M$, que representa o tempo de ativação da i -ésima causa latente. Assume-se que as variáveis W_i são independentes e identicamente distribuídas, com função de distribuição acumulada $F(\cdot)$ e função de sobrevivência $S(\cdot) = 1 - F(\cdot)$.

O tempo de falha observável Y é definido como

$$Y = \min\{W_1, \dots, W_M\}, \quad (2.3)$$

com a convenção de que $Y = \infty$ quando $M = 0$ (COX; OAKES, 1984).

A função de sobrevivência da população é obtida por meio da Lei da Probabilidade Total condicionada ao número de causas latentes:

$$S_{\text{pop}}(y) = \sum_{m=0}^{\infty} P(Y > y \mid M = m)P(M = m). \quad (2.4)$$

Para $m = 0$, tem-se $P(Y > y \mid M = 0) = 1$, enquanto para $m \geq 1$ a sobrevivência ocorre se todas as causas latentes não se ativarem até o tempo y , isto é, $P(Y > y \mid M = m) = [S(y)]^m$. Assim,

$$S_{\text{pop}}(y) = \sum_{m=0}^{\infty} P(M = m)[S(y)]^m. \quad (2.5)$$

Em virtude da independência das variáveis W_i , essa expressão pode ser escrita de forma compacta como

$$S_{\text{pop}}(y) = G_M(S(y)), \quad (2.6)$$

onde $G_M(\cdot)$ denota a função geradora de probabilidade de M , definida por

$$G_M(s) = \mathbb{E}(s^M) = \sum_{m=0}^{\infty} P(M = m)s^m.$$

2.3 MODELO BINOMIAL NEGATIVO COM FRAÇÃO DE CURA E RISCOS COMPETITIVOS LATENTES

Na sequência, é desenvolvida a estrutura matemática que fundamenta os riscos competitivos bem como a respectiva função de probabilidade relacionada a tal formulação.

2.3.1 DISTRIBUIÇÃO DO NÚMERO DE CAUSAS LATENTES

A escolha da distribuição do número de causas latentes é crucial, pois define o mecanismo estocástico subjacente ao processo de falha. Diversas alternativas têm sido propostas

na literatura, incluindo modelos baseados em distribuições de Poisson truncada (LOUZADA; CANCHO; BARRIGA, 2012) e extensões da distribuição geométrica (LOUZADA et al., 2014). No entanto, tais abordagens podem apresentar limitações na presença de heterogeneidade não observada e sobredispersão.

Seguindo Cancho et al. (2013) e Pal e Balakrishnan (2016), assume-se neste trabalho que o número de causas latentes M segue uma distribuição Binomial Negativa, devido à sua elevada flexibilidade e capacidade de acomodar diferentes regimes de dispersão. Essa distribuição permite que a variância exceda a média, fenômeno frequentemente observado em dados biomédicos e de confiabilidade.

Adota-se a reparametrização clássica apresentada por Anscombe (1950) e discutida em Piegorsch (1990), considerando $M \sim \text{BN}(\eta, \phi)$, cuja função massa de probabilidade é dada por

$$P(M = m; \eta, \phi) = \frac{\Gamma\left(m + \frac{1}{\phi}\right)}{\Gamma\left(\frac{1}{\phi}\right) m!} \left(\frac{\phi\eta}{1 + \phi\eta}\right)^m \left(\frac{1}{1 + \phi\eta}\right)^{1/\phi}, \quad m = 0, 1, 2, \dots, \quad (2.7)$$

com $\eta > 0$ e $\phi > 0$. Nessa parametrização, tem-se

$$\mathbb{E}(M) = \eta, \quad \text{Var}(M) = \eta + \phi\eta^2,$$

evidenciando a presença de sobredispersão quando $\phi > 0$. No limite em que $\phi \rightarrow 0$, a distribuição Binomial Negativa converge para a distribuição de Poisson com média η (ANSCOMBE, 1950).

2.3.2 FUNÇÃO DE SOBREVIVÊNCIA POPULACIONAL

De acordo com Rodrigues et al. (2009), a função geradora de probabilidade associada à distribuição Binomial Negativa pode ser expressa como

$$G_M(S(y)) = \{1 + \phi\eta(1 - S(y))\}^{-1/\phi}, \quad 0 \leq S(y) \leq 1. \quad (2.8)$$

Substituindo (2.8) em (2.6), obtém-se a função de sobrevivência da população:

$$S_{\text{pop}}(y) = \{1 + \phi\eta(1 - S(y))\}^{-1/\phi} = \{1 + \phi\eta F(y)\}^{-1/\phi}. \quad (2.9)$$

Como o tempo é tratado de forma discreta, a função de probabilidade da população é obtida pela diferença entre probabilidades de sobrevivência consecutivas:

$$f_{\text{pop}}(y) = S_{\text{pop}}(y) - S_{\text{pop}}(y + 1). \quad (2.10)$$

Substituindo (2.9) em (2.10), tem-se

$$f_{\text{pop}}(y) = \{1 + \phi\eta F(y)\}^{-1/\phi} - \{1 + \phi\eta F(y + 1)\}^{-1/\phi}. \quad (2.11)$$

2.3.3 FRAÇÃO DE CURA E INTERPRETAÇÃO DOS PARÂMETROS

A partir da definição de fração de cura, temos que ela é dado por:

$$p_0 = \left(\frac{1}{1 + \phi\eta} \right)^{1/\phi}. \quad (2.12)$$

A expressão (2.12) evidencia que a fração de cura é inversamente relacionada ao número médio de causas latentes η e modulada pelo parâmetro de dispersão ϕ . Para permitir a incorporação de covariáveis na modelagem da fração de cura, reparametriza-se η em função de p_0 da seguinte forma:

$$\eta = \frac{p_0^{-\phi} - 1}{\phi}. \quad (2.13)$$

Os parâmetros do modelo possuem interpretação direta. O parâmetro η representa o número médio de riscos competitivos latentes associados a cada indivíduo (CANCHO; RODRIGUES; CASTRO, 2011), enquanto o parâmetro ϕ controla o grau de heterogeneidade não observada entre os indivíduos, regulando a dispersão do número de causas latentes (TRESZOKS; PAL, 2023). Essa estrutura confere maior plausibilidade biológica ao modelo e amplia sua aplicabilidade empírica.

2.4 DISTRIBUIÇÃO LOGNORMAL DISCRETA

A modelagem dos tempos de ativação latentes é realizada assumindo que estes sigam uma *distribuição lognormal discreta*, denotada por LND. Especificamente, considera-se que

$$W_1, W_2, \dots, W_M \stackrel{i.i.d.}{\sim} \text{LND}(\mu, \sigma),$$

onde $\mu \in \mathbb{R}$ e $\sigma > 0$ são, respectivamente, os parâmetros de localização e escala.

A distribuição lognormal discreta (LND) foi introduzida por Lyu e Nadarajah (2022) como uma discretização natural da distribuição lognormal contínua originalmente proposta por McAlister (1879). A versão contínua é amplamente empregada em análise de sobrevivência e já foi explorada em modelos com fração de cura, como em Taweab, Al-Moisheer e Al-Moisheer (2012), o que fornece sustentação teórica consistente para sua adoção no presente contexto de riscos competitivos latentes.

Enquanto Lyu e Nadarajah (2022) definem diretamente uma variável discreta $X \sim \text{LND}(\mu, \sigma)$ com suporte nos inteiros positivos ($x = 1, 2, \dots$), neste trabalho adota-se a transformação $W = X - 1$, de modo que os tempos latentes possam assumir valores maiores ou iguais a zero, indo de acordo com a aplicação, que apresenta tempos iguais a zero.

A seguir, apresentam-se as principais funções associadas à distribuição Lognormal Discreta, necessárias para a construção do modelo de sobrevivência populacional.

A função massa de probabilidade de W é dada por

$$f_W(w) = \Phi\left(\frac{\log(w+1) - \mu}{\sigma}\right) - \Phi\left(\frac{\log(w) - \mu}{\sigma}\right), \quad (2.14)$$

para $w = 0, 1, 2, \dots$, em que $\Phi(\cdot)$ denota a função de distribuição acumulada da normal padrão.

A função de sobrevivência discreta associada é definida como

$$S(w \mid \mu, \sigma) = \Pr(W > w) = 1 - \Phi\left(\frac{\log(w) - \mu}{\sigma}\right), \quad w = 0, 1, 2, \dots \quad (2.15)$$

A função de risco discreta correspondente é expressa por

$$h(w \mid \mu, \sigma) = \frac{\Phi\left(\frac{\log(w+1) - \mu}{\sigma}\right) - \Phi\left(\frac{\log(w) - \mu}{\sigma}\right)}{1 - \Phi\left(\frac{\log(w) - \mu}{\sigma}\right)}. \quad (2.16)$$

A função de risco discreta representa a probabilidade condicional de ativação de uma causa latente no tempo w , dado que esta não ocorreu até o instante anterior.

A função quantílica da LND pode ser obtida a partir da função quantílica da normal padrão, sendo dada por

$$Q(p) = \lfloor \exp(\mu + \sigma\Phi^{-1}(p)) \rfloor, \quad (2.17)$$

em que $\Phi^{-1}(\cdot)$ denota a função quantílica da normal padrão e $\lfloor \cdot \rfloor$ representa a função parte inteira. Em particular, a mediana da distribuição é dada por

$$\text{Med}(W) = \lfloor \exp(\mu) \rfloor.$$

Os momentos da distribuição lognormal discreta não admitem forma fechada simples e são definidos por meio de somas infinitas. Em particular, para $k = 1, 2, \dots$, tem-se

$$E(W^k) = \sum_{w=0}^{\infty} (w+1)^k \left[\Phi\left(\frac{\log(w+1) - \mu}{\sigma}\right) - \Phi\left(\frac{\log(w) - \mu}{\sigma}\right) \right], \quad (2.18)$$

desde que as séries sejam convergentes.

De forma análoga, a função geradora de momentos pode ser expressa como

$$E\{\exp(tW)\} = \sum_{k=0}^{\infty} \frac{t^k}{k!} \sum_{w=0}^{\infty} (w+1)^k \left[\Phi\left(\frac{\log(w+1) - \mu}{\sigma}\right) - \Phi\left(\frac{\log(w) - \mu}{\sigma}\right) \right].$$

Embora os momentos da distribuição lognormal discreta não sejam utilizados diretamente no procedimento inferencial adotado neste trabalho, sua apresentação contribui para

evidenciar a flexibilidade da distribuição e a riqueza de sua estrutura probabilística, além de reforçar sua adequação à modelagem de tempos discretos com elevada variabilidade.

A distribuição lognormal discreta constitui, portanto, uma alternativa flexível e robusta para a modelagem de tempos discretos, especialmente em contextos nos quais distribuições tradicionais apresentam dificuldades em capturar elevada variabilidade temporal ou padrões assimétricos de risco. Ademais, seus parâmetros preservam interpretação direta, permitindo relacionar medidas de posição dos tempos de falha a covariáveis de interesse. Nesse sentido, a LND surge como uma alternativa natural à distribuição Weibull discreta, amplamente explorada na literatura de análise de sobrevivência, como em Oliveira, Cancho e Louzada (2019), Brunello e Nakano (2015), Achcar et al. (2021) e Silva, Otiniano e Nakano (2019).

2.5 MODELO DE REGRESSÃO

No modelo estatístico proposto, o efeito de covariáveis é incorporado por meio de estruturas de regressão associadas aos parâmetros fundamentais do modelo, utilizando funções de ligação adequadas. Essa abordagem permite avaliar de forma direta como características individuais influenciam a fração de cura, a heterogeneidade não observada e a distribuição dos tempos de ativação latentes.

Seja $\mathbf{x}_i$ o vetor de covariáveis associado ao indivíduo i . Os parâmetros do modelo são relacionados linearmente às covariáveis por meio das seguintes funções de ligação:

$$\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}_\mu, \quad \sigma_i = \exp(\mathbf{x}_i^\top \boldsymbol{\beta}_\sigma), \quad p_{0i} = \frac{1}{1 + \exp(-\mathbf{x}_i^\top \boldsymbol{\beta}_{p_0})}, \quad \phi_i = \exp(\mathbf{x}_i^\top \boldsymbol{\beta}_\phi), \quad (2.19)$$

onde $\boldsymbol{\beta}_\mu$, $\boldsymbol{\beta}_\sigma$, $\boldsymbol{\beta}_{p_0}$ e $\boldsymbol{\beta}_\phi$ denotam os vetores de coeficientes de regressão associados, respectivamente, aos parâmetros de localização, dispersão, fração de cura e heterogeneidade não observada. Além disso, a depender da aplicação, os regressores $\mathbf{x}_i$ não precisam ser necessariamente os para os parâmetros.

Os parâmetros μ_i e σ_i controlam, respectivamente, a localização e a escala da distribuição lognormal discreta que governa os tempos de ativação latentes. O parâmetro p_{0i} representa a fração de cura do indivíduo i , isto é, a probabilidade de que nenhum risco latente esteja ativo. Por sua vez, ϕ_i corresponde ao parâmetro de dispersão da distribuição binomial negativa associada ao número de riscos competitivos latentes, sendo responsável por capturar a variabilidade interindividual não explicada pelas covariáveis observadas. Valores de $\phi_i > 0$ permitem acomodar

dar sobredispersão em relação ao modelo de Poisson, frequentemente observada em aplicações biomédicas.

A escolha das funções de ligação exponencial e logística assegura que os parâmetros permaneçam restritos a seus domínios naturais (positividade e intervalo unitário) e segue práticas consolidadas na literatura de modelos lineares generalizados, conforme discutido em Dobson (2002) e Kutner et al. (2005), porém outras podem ser escolhidas de acordo com a necessidade do problema.

2.6 ESTIMAÇÃO DOS PARÂMETROS POR MÁXIMA VEROSSIMILHANÇA

Considere uma amostra composta por n indivíduos independentes. Para o indivíduo i , seja T_i o tempo observado, definido por

$$T_i = \min\{Y_i, C_i\},$$

onde C_i denota o tempo de censura à direita e Y_i representa o tempo de falha latente. No contexto do modelo de riscos competitivos latentes, o tempo de falha é definido como

$$Y_i = \min\{W_{i1}, \dots, W_{iM_i}\},$$

em que M_i corresponde ao número de causas latentes associadas ao indivíduo i e W_{ij} representa o tempo de ativação da j -ésima observação.

Define-se ainda o indicador de censura δ_i , tal que $\delta_i = 1$ se a falha é observada ($T_i = Y_i$) e $\delta_i = 0$ se a observação é censurada à direita ($T_i = C_i$).

Seja $\boldsymbol{\theta} = (\mu_i, \sigma_i, p_{0i}, \phi_i)$ o vetor de parâmetros do modelo, que inclui os parâmetros associados à distribuição dos tempos latentes, à fração de cura e à distribuição binomial negativa do número de riscos latentes. Sob o pressuposto de independência entre os tempos de falha latentes e os tempos de censura, a função de verossimilhança associada aos dados observados

$$\mathcal{D} = \{(t_i, \delta_i, \mathbf{x}_i)\}_{i=1}^n$$

é dada por

$$L(\boldsymbol{\theta}) = \prod_{i=1}^n [f_{\text{pop}}(t_i; \boldsymbol{\theta})]^{\delta_i} [S_{\text{pop}}(t_i; \boldsymbol{\theta})]^{1-\delta_i}, \quad (2.20)$$

em que $f_{\text{pop}}(\cdot)$ e $S_{\text{pop}}(\cdot)$ denotam, respectivamente, a função de massa de probabilidade populacional e a função de sobrevivência populacional. Essa forma da verossimilhança reflete a

contribuição distinta de observações censuradas e não censuradas no contexto de dados discretos.

A log-verossimilhança correspondente é expressa por

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^n \{ \delta_i \log [f_{\text{pop}}(t_i; \boldsymbol{\theta})] + (1 - \delta_i) \log [S_{\text{pop}}(t_i; \boldsymbol{\theta})] \}. \quad (2.21)$$

Devido à elevada complexidade analítica da função de log-verossimilhança, não é possível obter expressões fechadas para suas derivadas. Dessa forma, a estimação dos parâmetros por máxima verossimilhança é realizada por meio de procedimentos de otimização numérica. Neste trabalho, a maximização da log-verossimilhança foi conduzida utilizando o algoritmo quasi-Newton de Broyden–Fletcher–Goldfarb–Shanno (BFGS) (BROYDEN, 1970; FLETCHER, 1970; GOLDFARB, 1970; SHANNO, 1970), complementado pelo algoritmo de *Simulated Annealing* de Metropolis et al. (1953) e Kirkpatrick, Gelatt e Vecchi (1983), ambos implementados no ambiente computacional R usando a função "optim" do pacote "stats".

De forma geral, o código utilizado na aplicação empírica deste trabalho (ver Apêndice) é estruturado nas seguintes etapas:

- especificação das covariáveis associadas a cada parâmetro do modelo;
- implementação da função de verossimilhança descrita nesta seção;
- maximização numérica da log-verossimilhança;
- cálculo dos erros-padrão a partir da matriz Hessiana observada.

Após a estimação, intervalos de confiança para o vetor de parâmetros $\boldsymbol{\theta}$ são construídos com base nas propriedades assintóticas dos estimadores de máxima verossimilhança (MOOD; GRAYBILL; BOES, 1974; CASELLA; BERGER, 2002). Sob condições de regularidade apropriadas, o estimador $\hat{\boldsymbol{\theta}}$ é assintoticamente normal, com matriz de variância-covariância dada pelo inverso da matriz de Informação de Fisher.

Cabe destacar, contudo, que a verificação analítica dessas condições de regularidade é particularmente desafiadora em modelos com fração de cura e riscos competitivos latentes (MALLER; ZHOU, 1996). Por essa razão, um estudo de simulação é conduzido na seção subsequente com o objetivo de investigar empiricamente as propriedades assintóticas dos estimadores de máxima verossimilhança, abordagem amplamente adotada na literatura recente.

3 RESULTADOS E DISCUSSÕES

Ao começo desta seção, apresenta-se de maneira detalhada o modelo aplicado ao contexto do infarto do miocárdio e o ajuste da regressão. Ao final, é apresentado o estudo de simulação e seus resultados. Todos os códigos utilizados para realizar essas tarefas podem ser encontrados neste link.

3.1 APLICAÇÃO

Em seguida, mostra-se as características mais relevantes sobre os dados, e posteriormente o ajuste. Vale ressaltar, que o modelo final apresenta duas covariáveis para a fração de cura e para a média, já para os demais parâmetros foram considerados somente o intercepto, escolha feita depois de se comparar o modelo final via teste da razão de verossimilhança com diversos ajustes anteriores que apresentavam covariáveis ligadas aos demais parâmetros. O conjunto apresenta diversas variáveis, porém para esse estudo, limitou-se a considerar apenas duas, o sexo e a idade.

3.1.1 DESCRIÇÃO DOS DADOS

A aplicação empírica do modelo proposto na Seção 2 é realizada utilizando um conjunto de dados referentes a pacientes acometidos por infarto agudo do miocárdio. Os dados foram extraídos do estudo apresentado em Carvalho et al. (2005), que analisou internações registradas no Sistema Único de Saúde (SUS) no município do Rio de Janeiro.

O banco de dados, disponibilizado no arquivo `infarto.dat`, contém informações coletadas no ano de 2005 com o objetivo de avaliar o efeito de características individuais dos pacientes, como sexo e idade, bem como de atributos institucionais dos hospitais, incluindo volume de internações, número de leitos de UTI e natureza jurídica. Ao todo, o conjunto de dados é composto por 3.176 observações independentes.

A Tabela 1 apresenta a descrição das variáveis disponíveis no banco de dados.

Uma análise descritiva inicial revela que aproximadamente 62,81% dos pacientes são do sexo masculino, enquanto 37,19% são do sexo feminino. A idade média é de 60,96 anos, com desvio-padrão de 12,96 anos.

Observa-se ainda uma elevada proporção de observações censuradas, correspondendo

Tabela 1 – Descrição das variáveis do banco de dados `infarto.dat`

Variável	Descrição
hospital	Identificador do hospital
id	Identificador do paciente
ini	Data de ocorrência do infarto
fim	Data do óbito ou da censura
status	0 = censura, 1 = óbito
sexo	F = feminino, M = masculino
idade	Idade na data do infarto
volume	Número de internações: $vp < 25$, $vg \geq 25$
luti	Leitos de UTI: nenhum, 1–24, 25+
natureza	Natureza jurídica do hospital

a aproximadamente 81,86% da amostra. Esse elevado nível de censura reforça a adequação do uso de modelos de sobrevivência com fração de cura, amplamente empregados em estudos envolvendo doenças cardiovasculares, conforme discutido detalhadamente, por exemplo, em Sevilimedu et al. (2021) e Bruno et al. (2023). Antes do ajuste, foi realizado o teste de Maller e Zhou (1995) para se verificar estatisticamente a presença de cura nos dados, ele foi calculado para cada categoria descrita em 2 e indicou a presença de cura para tais categorias ($p < 0.05$).

A Tabela 2 apresenta a distribuição de eventos e censuras estratificada por grupos definidos a partir de idade e sexo.

Tabela 2 – Distribuição de censura e eventos por grupo de covariáveis

Idade	Sexo	n_{total}	$n_{\text{censurados}}$	Eventos	% Censura
< 65	F	589	509	80	86,4
< 65	M	1279	1149	130	89,8
≥ 65	F	592	402	190	67,9
≥ 65	M	716	540	176	75,4

3.1.2 ESPECIFICAÇÃO DO MODELO

O evento de interesse é o óbito ocorrido após o infarto do miocárdio. O tempo de sobrevivência é definido como a diferença entre a data do desfecho (óbito ou censura) e a data do infarto, registrado em valores inteiros considerando a unidade de tempo em meses.

No contexto do modelo de riscos competitivos latentes apresentado na Seção 2, considera-se que o número de causas latentes M representa mecanismos fisiopatológicos não observáveis associados ao óbito pós-infarto, tais como aterosclerose avançada, ruptura de placas coronarianas ou trombose aguda. Os tempos de ativação dessas causas são representados pelas variáveis

latentes W_i , assumidas como independentes e identicamente distribuídas segundo a distribuição lognormal discreta.

Para a aplicação empírica, foram selecionadas como covariáveis:

- x_1 : idade categorizada em < 65 anos e ≥ 65 anos;
- x_2 : sexo (feminino e masculino).

Os parâmetros de localização da distribuição lognormal discreta (μ) e da fração de cura (p_0) foram modelados como funções dessas covariáveis. Os parâmetros de dispersão σ e ϕ foram mantidos constantes ao longo da população.

3.1.3 ANÁLISE DE AJUSTE E RESULTADOS

Para avaliar a adequação do modelo aos dados, foi inicialmente aplicado o teste de Log-Rank (COLOSIMO; GIOLO, 2006), comparando as curvas de sobrevivência entre os quatro grupos definidos por idade e sexo. Os resultados são apresentados na Tabela 3.

Tabela 3 – Teste de Log-Rank por grupos de idade e sexo

Grupo	N	Observado	Esperado	$(O - E)^2/E$	$(O - E)^2/V$
$< 65, F$	589	80	109	7,76	9,72
$< 65, M$	1279	130	240	50,73	88,46
$\geq 65, F$	592	190	100	80,29	98,84
$\geq 65, M$	716	176	126	19,67	25,58
Qui-quadrado = 161 $df = 3$ $p < 0,005$					

Os resultados indicam diferenças estatisticamente significativas entre as distribuições de sobrevivência dos grupos, justificando a inclusão das covariáveis no modelo. Ressalta-se que, embora o teste de Log-Rank seja fundamentado em modelos de sobrevivência sem fração de cura, seus resultados fornecem uma evidência exploratória relevante da heterogeneidade entre os grupos analisados. Dessa forma, o teste é utilizado neste estudo como uma ferramenta preliminar para justificar a inclusão das covariáveis no modelo proposto, não substituindo a inferência baseada no modelo com fração de cura ajustado aos dados.

A Figura 1 compara as curvas de sobrevivência estimadas pelo modelo com as estimativas empíricas de Kaplan–Meier, evidenciando um bom ajuste global e a presença de uma fração de cura distinta de zero.




Figura 1 – Curvas de Kaplan-Meier (linhas) e de sobrevivência ajustada pelo modelo (pontos)

Os resultados da estimação dos parâmetros são apresentados na Tabela 4. Os sinais e magnitudes dos coeficientes estimados permitem uma interpretação consistente do efeito das covariáveis sobre o tempo de sobrevivência e a fração de cura. Em particular, o coeficiente positivo associado à variável indicadora de idade igual ou superior a 65 anos no parâmetro de localização da distribuição lognormal discreta indica que indivíduos mais idosos apresentam tempos médios de ativação das causas latentes mais elevados, quando comparados aos indivíduos com menos de 65 anos. Por outro lado, o coeficiente negativo associado à idade no componente da fração de cura evidencia uma redução significativa da proporção de indivíduos de longa duração entre pacientes mais idosos, sugerindo maior vulnerabilidade ao óbito pós-infarto nesse grupo.

Tabela 4 – Estimativas de máxima verossimilhança dos coeficientes e significância estatística (95 %) via teste t

Coeficiente	Estimativa	desvio-padrão	$ t $	p-valor
β_{σ_0} (Intercepto)	0.5780	0.0731	7.9112	< 0.005
β_{μ_0} (Intercepto)	2.7539	0.6748	4.0808	< 0.005
β_{μ_1} (≥ 65)	1.9370	0.8206	2.3603	0.0182
β_{μ_2} (Masculino)	-0.8877	0.3912	2.2694	0.0232
$\beta_{p_{00}}$ (Intercepto)	1.6884	0.1116	15.1263	< 0.005
$\beta_{p_{01}}$ (≥ 65)	-1.2070	0.1171	10.3065	< 0.005
$\beta_{p_{02}}$ (Masculino)	0.4204	0.1057	3.9748	< 0.005
β_{ϕ_0} (Intercepto)	2.2975	0.4958	4.6334	< 0.005

No que se refere ao sexo, observa-se que indivíduos do sexo masculino apresentam me-

nor tempo médio de falha, conforme indicado pelo coeficiente negativo associado ao parâmetro de localização da distribuição lognormal discreta, bem como uma fração de cura estatisticamente distinta daquela observada entre indivíduos do sexo feminino. Esses resultados estão em consonância com evidências clínicas amplamente documentadas na literatura sobre doenças cardiovasculares, nas quais idade avançada e sexo masculino figuram como fatores de risco relevantes.

Observando a Tabela 5, nota-se que indivíduos com idade inferior a 65 anos apresentam uma cura maior do que os indivíduos mais idosos, além disso para ambos temos que mais da metade dos indivíduos apresentam cura. Para ambas as faixas etárias consideradas, nota-se que a cura de indivíduos do sexo masculino um pouco maiores do que o sexo feminino.

Tabela 5 – Estimativas da Fração de Cura (p_0), Variância e Intervalos de Confiança de 95%

Grupo	Estimativa p_0	Desvio-padrão	Limite inferior	Limite superior
Masculino (< 65)	0,8917	0,0086	0,8736	0,9076
Feminino (< 65)	0,8440	0,0298	0,8130	0,8707
Masculino ($\geq$ 65)	0,7113	0,0245	0,6611	0,7568
Feminino ($\geq$ 65)	0,6181	0,029825	0,5582	0,6746

Por fim, a análise de resíduos quantílicos, acompanhada de envelopes simulados (DUNN; SMYTH, 1996; ATKINSON, 1985), não indicou violações sistemáticas das suposições do modelo, conforme ilustrado na Figura 2, corroborando a adequação do ajuste.




Figura 2 – Envelope Simulado

De forma geral, os resultados obtidos evidenciam que o modelo de sobrevivência em tempo discreto com fração de cura e riscos competitivos latentes apresenta bom desempenho na análise de dados de pacientes acometidos por infarto agudo do miocárdio. O modelo mostrou-se capaz de capturar adequadamente a elevada proporção de censura observada na amostra, bem como de identificar efeitos significativos das covariáveis idade e sexo tanto sobre o tempo de sobrevivência quanto sobre a fração de indivíduos de longa duração. Esses achados reforçam a flexibilidade e a aplicabilidade do modelo proposto em contextos epidemiológicos caracterizados por heterogeneidade não observada e presença de indivíduos curados, consolidando sua relevância como ferramenta analítica para estudos em saúde pública e avaliação de desfechos em doenças crônicas.

3.2 SIMULAÇÃO

Com o objetivo de avaliar as propriedades frequentistas dos estimadores de máxima verossimilhança do modelo proposto, foi conduzido um estudo de simulação de Monte Carlo sob diferentes cenários. Todo o estudo foi implementado na linguagem R (RStudio Team, 2023).

Este estudo de simulação foi realizado em um ambiente computacional com as seguintes especificações: sistema operacional Ubuntu 24.04.3 LTS (64 bits); modelo de *hardware* Dell Inc. (Vostro 3300); processador Intel® Core™ i3 M 370 (4 threads); memória RAM de 4,0 GiB; capacidade de disco de 320,1 GB; arquitetura x86_64.

Diferentes níveis de censura foram considerados por meio da fixação da proporção de indivíduos suscetíveis à censura, denotada por $p_{\text{susc}} \in \{0,05, 0,10, 0,15\}$. Para introduzir censura aleatória à direita, os tempos de censura foram gerados a partir de uma distribuição uniforme discreta com suporte $\{1, 2, \dots, \tau\}$, em que o valor de τ foi escolhido de forma a controlar a proporção desejada de observações censuradas.

A proporção de observações censuradas, denotada por p_c , foi determinada pela soma da fração de cura p_0 e da proporção de indivíduos suscetíveis censurados

$$p_c = p_0 + p_{\text{susc}}$$

Ressalta-se que, para cada observação simulada, apenas um dos dois desfechos é observado, falha ou censura, de modo que, assim como em conjuntos de dados reais, não é possível distinguir diretamente indivíduos curados de indivíduos censurados (BORGES; RODRIGUES, 2025).

O tamanho amostral, n , é definido no conjunto $\{100, 200, 300, 400, 500, 700, 1000\}$, e o número de repetições Monte Carlo (denotado por R) 1000. Os tempos observados e os indicadores de censura foram gerados seguindo os seguintes passos:

1. Fixar os valores dos parâmetros $\theta = (\mu_i, \sigma_i, p_{0i}, \phi_i)$.
2. Gerar n valores para as covariáveis a partir de uma distribuição Bernoulli(0.5). Para cada observação $i = 1, \dots, n$, calcula-se σ_i, μ_i, p_{0i} e ϕ_i .
3. Gerar o número de riscos latentes (M_i). O número de eventos de risco latentes M_i para o indivíduo i é gerado a partir de uma binomial negativa, definida na seção 2.3
4. Gerar do tempo de falha latente (Y_i), definido como:

$$Y_i = \begin{cases} \min \{W_{i,1}, \dots, W_{i,M_i}\} & \text{se } M_i > 0 \quad (\text{Suscetível}) \\ \infty & \text{se } M_i = 0 \quad (\text{Curado}) \end{cases}$$

onde $W_{i,j} \sim \text{LND}(\mu_i, \sigma_i)$ (lognormal discreta), gerado pelo método da inversa usando a equação 2.17.

5. Gerar o tempo de censura proveniente de uma uniforme discreta no intervalo $[1, \tau_i]$. O valor de τ_i é encontrado como a raiz da seguinte equação:

$$\frac{1}{\tau_i} \sum_{c=1}^{\tau_i} \left[1 - \Phi \left(\frac{\log(c-1) - \mu}{\sigma} \right) \right]^m - p_{\text{susc}} = 0$$

O limite τ_i é determinado numericamente pela função ‘uniroot’ para cada padrão de covariável. O expoente m é número de causas latentes.

6. O tempo de observação Y_i e o indicador de evento δ_i são determinados por:

$$T_i = \min(Y_i, C_i)$$

$$\delta_i = \mathbf{I}(Y_i \leq C_i)$$

7. Repetir os passos 3 ao 6 para todo $i = 1, \dots, n$, formando assim o conjunto de dados.

O conjunto de dados simulado é dado por $\{Y_i, \mathbf{x}_i, \delta_i\}_{i=1}^n$. Para cada conjunto de dados simulado, a estimação dos parâmetros é realizada exatamente igual a aplicação. O processo de estimação é repetido $R = 1000$ vezes para cada tamanho amostral.

3.2.1 CENÁRIOS DE SIMULAÇÃO

Foram considerados dois cenários distintos de simulação. Essa escolha se justifica pelo fato de que, na aplicação empírica apresentada na Seção 3.1, observou-se um elevado percentual de censura em determinados estratos das covariáveis. Nessas condições, a combinação de valores elevados de p_{susc} com estruturas de regressão mais complexas pode levar a situações degeneradas, como estratos com 100% de observações censuradas, inviabilizando a estimação por máxima verossimilhança.

Dessa forma, os dois cenários foram definidos com objetivos complementares: o primeiro visa avaliar o desempenho do modelo em condições próximas às observadas nos dados reais, enquanto o segundo investiga o comportamento dos estimadores em um contexto mais controlado e balanceado, com diferentes níveis de fração de cura e censura.

- **Cenário 1 (Baseado na aplicação empírica).** Neste cenário, considerou-se apenas $p_{\text{susc}} = 5\%$. As covariáveis foram duas variáveis preditoras binárias, x_1 e x_2 , selecionadas com base na aplicação empírica discutida na Seção 3.1. Ambas foram geradas a partir de uma distribuição de Bernoulli com parâmetro 0,5. A variável x_1 representa a idade (0: < 65 anos; 1: ≥ 65 anos) e x_2 representa o sexo (0: feminino; 1: masculino).

Os valores verdadeiros dos parâmetros utilizados para a geração dos dados foram fixados como sendo as estimativas de máxima verossimilhança obtidas na análise do conjunto de dados real. Essa escolha permite avaliar se, sob condições semelhantes às observadas empiricamente, os estimadores apresentam bom desempenho assintótico. Os valores considerados são apresentados na Tabela 6.

Tabela 6 – Valores fixados dos parâmetros no Cenário 1 da simulação

Parâmetro	Valor
β_{σ_0}	0.5780
β_{μ_0}	2.7539
β_{μ_1}	1.9370
β_{μ_2}	-0.8877
$\beta_{p_{00}}$	1.6884
$\beta_{p_{01}}$	-1.2070
$\beta_{p_{02}}$	0.4203
β_{ϕ_0}	2.2975

- **Cenário 2 (Estrutura controlada com três níveis).** No segundo cenário, foram considerados $p_{\text{susc}} \in \{5\%, 10\%, 15\%$ e uma única variável preditora categórica, denotada

por x , gerada a partir de uma distribuição uniforme discreta com suporte $\{1, 2, 3\}$. Essa variável foi codificada por meio de três variáveis indicadoras, tomando o nível 1 como categoria de referência.

As frações de cura associadas aos níveis 1, 2 e 3 foram fixadas, respectivamente, em 40%, 30% e 20%, permitindo avaliar o desempenho do modelo em um cenário com heterogeneidade estruturada na fração de cura. Os valores dos parâmetros utilizados para a geração dos dados encontram-se na Tabela 7.

Tabela 7 – Valores fixados dos parâmetros no Cenário 2 da simulação

Parâmetro	Valor
β_{σ_0}	0.2000
β_{μ_0}	5.0000
$\beta_{p_{00}}$	-0.4055
$\beta_{p_{01}}$	-0.4418
$\beta_{p_{02}}$	-0.9808
β_{ϕ_0}	0.8000

3.2.2 ANÁLISE DAS PROPRIEDADES DOS ESTIMADORES

Ao final são calculadas métricas de desempenho para a verificação das propriedades:

- Bias (Vício): A diferença média entre as estimativas e o valor verdadeiro θ_{true} :

$$\text{Bias}(\hat{\theta}) = \frac{1}{R} \sum_{j=1}^R (\hat{\theta}_j - \theta_{\text{true}})$$

- Raiz do Erro Quadrático Médio (RSME): Uma medida da precisão e variabilidade:

$$\text{RMSE}(\hat{\theta}) = \sqrt{\frac{1}{R} \sum_{j=1}^R (\hat{\theta}_j - \theta_{\text{true}})^2}$$

- Largura Média (AW): A largura média dos ICs:

$$\text{AW} = \frac{1}{R} \sum_{j=1}^R (\text{IC}_{j,\text{superior}} - \text{IC}_{j,\text{inferior}})$$

- Probabilidade de Cobertura (CP): A proporção de simulações onde o IC de 95% contém o valor verdadeiro:

$$\text{CP} = \frac{1}{R} \sum_{j=1}^R \mathbf{I}(\theta_{\text{true}} \in [\text{IC}_{j,\text{inferior}}, \text{IC}_{j,\text{superior}}])$$

Todas essas métricas estão sendo apresentadas nos gráficos da próxima seção.

3.2.3 RESULTADOS DA SIMULAÇÃO (CENÁRIO 1)

Para os parâmetros de probabilidade ($\beta_{p0,0}$, $\beta_{p0,1}$ e $\beta_{p0,2}$), o REQM e o vício diminuem de forma acentuada com o aumento do tamanho amostral (n), apresentando valores iniciais relativamente baixos em $n = 100$. O CP para os parâmetros $\beta_{p0,i}$ demonstra a convergência mais rápida, alcançando ou superando o nível de 95% em $n = 400$ (ex.: $\beta_{p0,0} = 0.952$). O AW para esses parâmetros apresenta um decréscimo constante e rápido, indicando um aumento de precisão. Para os demais parâmetros (β_{σ_0} , β_{μ_i} e β_{ϕ_0}), o REQM e o vício são inicialmente muito altos em $n = 100$ (REQM acima de 1.7 para β_{μ_i}), indicando dificuldade na estimação para amostras pequenas, como esperado. O CP para os parâmetros β_{μ_i} apresentam uma convergência mais lenta, melhorando substancialmente com o aumento de n . A Largura Média (AW) para os parâmetros β_{μ_i} e β_{ϕ_0} é inicialmente muito maior do que as dos parâmetros $\beta_{p0,i}$, mas decresce consistentemente com o aumento de n .




Figura 3 – Resultados da tabela 8.

3.2.4 RESULTADOS DA SIMULAÇÃO (CENÁRIO 2)

Para os parâmetros de probabilidade ($\beta_{p0,0}$, $\beta_{p0,1}$ e $\beta_{p0,2}$), o REQM e o vício diminuem bastante com o aumento do tamanho da amostra (n), apresentando os melhores resultados iní-

ais entre todos os grupos, com o vício bem baixo para $n \geq 500$ (ex.: $\beta_{p_{00}} = -0.000032$ em $n = 500$). O CP para os parâmetros $\beta_{p_{0i}}$ demonstra excelente desempenho e validade em amostras pequenas, estando próxima de 95% em $n = 100$ (ex.: $\beta_{p_{00}} = 0.941$). O AW apresenta um decréscimo rápido e constante. Para os parâmetros β_{σ_0} , β_{μ_0} e β_{ϕ_0} , o REQM e o vício diminuem consistentemente com o aumento de n , com o vício alcançando valores muito próximos de zero para β_{μ_0} e β_{σ_0} em $n \geq 500$. O CP para este grupo foi inicialmente baixo em $n = 100$ (entre 0.863 e 0.884). O CP atinge o nível de 95% para β_{σ_0} e β_{ϕ_0} em $n \geq 700$. No entanto, o parâmetro β_{μ_0} demonstra a convergência mais lenta, com o CP mais próximo do esperado de acordo com n aumenta. O AW decresce de forma constante, sendo inicialmente maior para β_{μ_0} , o que é consistente com seu REQM e vício inicial mais elevados.




Figura 4 – Resultados da tabela 9.

Para os parâmetros de probabilidade ($\beta_{p_{00}}$, $\beta_{p_{01}}$ e $\beta_{p_{02}}$), o REQM e o vício diminuem consistentemente com o aumento do tamanho da amostra (n), apresentando baixos valores iniciais. O vício se aproxima de zero rapidamente, sendo insignificante para $n \geq 500$ (ex.: $\beta_{p_{02}} = 0.006376$ em $n = 500$). O CP para os parâmetros $\beta_{p_{0i}}$ demonstra alta validade em amostras pequenas, estando próxima de 95% já em $n = 100$ (ex.: $\beta_{p_{00}} = 0.9458$). O AW apresenta um decréscimo rápido e constante, refletindo o aumento da precisão. Para os parâmetros β_{σ_0} , β_{μ_0}

e β_{ϕ_0} , o RSME e o vício diminuem consistentemente com o aumento de n . Os valores iniciais do REQM e vício são maiores do que os observados para $\beta_{p_{0i}}$, sendo β_{μ_0} o parâmetro com o vício inicial mais alto (0.119856 em $n = 100$). O CP para este grupo foi inicialmente baixa em $n = 100$ (entre 0.8532 e 0.8761). O CP converge bem, atingindo o nível de 95% ou mais para β_{σ_0} , β_{μ_0} e β_{ϕ_0} em $n \geq 500$. O parâmetro β_{μ_0} demonstra uma melhora no CP entre $n = 300$ (0.9378) e $n = 500$ (0.9521). O AW decresce de forma constante, sendo β_{μ_0} o parâmetro com a maior amplitude inicial (3.324692), o que é esperado devido ao seu Vício e REQM iniciais mais elevados.




Figura 5 – Resultados da tabela 10.

Para os parâmetros de probabilidade ($\beta_{p_{00}}$, $\beta_{p_{01}}$ e $\beta_{p_{02}}$), o REQM e o vício demonstram o comportamento esperado de decréscimo rápido com o aumento do tamanho da amostra (n). O vício para $\beta_{p_{02}}$ é praticamente nulo em todos os tamanhos de amostra (ex.: -0.000332 em $n = 100$), e o vício para $\beta_{p_{00}}$ se aproxima de zero rapidamente (0.000060 em $n = 1000$). O CP para os parâmetros $\beta_{p_{0i}}$ é consistentemente alta, estando próxima de 95% mesmo em $n = 100$. O CP estabiliza bem em torno de 95% para $n \geq 200$. O AW apresenta um decréscimo constante e substancial, indicando boa precisão assintótica. Para os parâmetros β_{σ_0} , β_{μ_0} e β_{ϕ_0} , o REQM e o vício diminuem consistentemente com o aumento de n . O CP converge bem, atingindo um

valor próximo a 95% para β_{σ_0} , β_{μ_0} e β_{ϕ_0} em $n \geq 500$ (ex.: β_{μ_0} atinge 0.9592 em $n = 700$). O AW decresce de forma constante para todos os parâmetros.




Figura 6 – Resultados da tabela 11.

4 CONCLUSÃO

Neste trabalho, foi proposto e avaliado um modelo de análise de sobrevivência com fração de cura com riscos competitivos latentes e tempo discreto. Sua construção foi baseada na aplicabilidade clínica, onde o tempo apresenta natureza discreta (meses, no caso da aplicação considerada), presença de indivíduos imunes (refletindo a alta censura nos dados depois de um grande período de observação, como os registros de infarto do miocárdio) e causas latentes (riscos competitivos latentes) que nesse contexto são as diversas causas do óbito relacionadas ao infarto. A quantidade de causas latentes foi modelada via distribuição binomial negativa com seus respectivos tempos de ativação lognormais discretos.

A análise baseada em dados de infarto do miocárdio do Sistema Único de Saúde (SUS) do Rio de Janeiro demonstrou que as covariáveis idade e sexo exercem papel fundamental na dinâmica de sobrevivência dos pacientes, sendo ambas estatisticamente significativas para os parâmetros de locação e probabilidade de cura do modelo. Os demais parâmetros também se apresentaram significantes, indicando um bom ajuste do modelo. Os teste de log-rank indicou que existe uma diferença estatisticamente significativa entre os quatro grupos definidos por idade e sexo $p \leq 0.005$, reforçando a necessidade de incluir ambas as covariáveis no preditor linear do modelo de regressão. O Kaplan–Meier também trouxe evidências fortes a favor da presença de cura nos dados, apresentando um comportamento de não tender a zero considerando o período de tempo de observação dos pacientes (60 meses). As variáveis sexo e idade se apresentaram significativas para explicar a fração de cura e a média dos tempos de ativação.

A abordagem adotada permitiu uma análise robusta mesmo diante de elevada proporção de censurados, reforçando a importância da modelagem de fração de cura em contextos clínicos semelhantes. O estudo de simulação, realizado sob diferentes cenários, evidenciou o comportamento assintótico desejado dos estimadores de máxima verossimilhança, com viés, erro quadrático médio e largura dos intervalos de confiança decrescendo conforme o aumento do tamanho amostral, e probabilidade de cobertura aproximando-se do nível de 0.95 de confiança para $n \geq 500$.

Os resultados obtidos mostram que o modelo proposto é eficiente e confiável para analisar dados de sobrevivência com cura sujeitos a granularidade temporal, além de fornecer estimativas interpretáveis e úteis para subsidiar decisões em saúde pública. Recomenda-se a continuidade de estudos que ampliem a aplicação do modelo para demais contextos biomédicos

e a inclusão de mais covariáveis para potencializar o entendimento dos fatores associados à sobrevivência e cura, além de também estender o trabalho para o caso de censura intervalar.

REFERÊNCIAS

- ACHCAR, Jorge Alberto et al. Classical and bayesian inference approaches for the exponentiated discrete weibull model with censored data and a cure fraction. **Pakistan Journal of Statistics and Operation Research**, v. 17, n. 2, p. 467–481, 2021.
- ALLISON, Paul D. Discrete-time methods for the analysis of event histories. **Sociological Methodology**, v. 13, p. 61–98, 1982.
- ANSCOMBE, F. J. Sampling theory of the negative binomial and logarithmic series distributions. **Biometrika**, [Oxford University Press, Biometrika Trust], v. 37, n. 3/4, p. 358–382, 1950. ISSN 00063444, 14643510. Disponível em: <<http://www.jstor.org/stable/2332388>>.
- ATKINSON, Anthony C. **Plots, Transformations and Regression: An Introduction to Graphical Methods of Diagnostic Regression Analysis**. Oxford: Clarendon Press, 1985. (Oxford Statistical Science Series).
- BALAKRISHNAN, Narayanaswamy; BARUI, Sandip. **Destructive cure models with proportional hazards lifetimes and associated likelihood inference**. 2021. Disponível em: <<https://arxiv.org/abs/2109.08661>>.
- BALAKRISHNAN, N.; FENG, T. Proportional odds under conway-maxwell-poisson cure rate model and associated likelihood inference. **STATISTICS, OPTIMIZATION AND INFORMATION COMPUTING**, International Academic Press, v. 6, n. 3, p. 305–334, 2018. Disponível em: <www.IAPress.org>.
- BERKSON, Joseph; GAGE, Robert P. Survival curve for cancer patients following treatment. **Journal of the American Statistical Association**, Taylor & Francis, v. 47, n. 259, p. 501–515, 1952.
- BEYERSMANN, Jan. Gerhard tutz and matthias schmid. modeling discrete time-to-event data. heidelberg, springer. **Biometrics**, v. 74, n. 1, p. 378–379, 03 2018. ISSN 0006-341X. Disponível em: <<https://doi.org/10.1111/biom.12849>>.
- BOAG, John W. Maximum likelihood estimates of the proportion of patients cured by cancer therapy. **Journal of the Royal Statistical Society. Series B (Methodological)**, v. 11, n. 1, p. 15–53, 1949. Disponível em: <<http://www.jstor.org/stable/2983694>>.
- BORGES, Patrick; RODRIGUES, Agatha. Cure rate regression model for turning point analysis in unimodal hazard functions. **Journal of Statistical Theory and Practice**, v. 19, 2025.
- BROYDEN, C. G. The convergence of a class of double-rank minimization algorithms. **Journal of the Institute of Mathematics and Its Applications**, v. 6, n. 1, p. 76–90, 1970.
- BRUNELLO, G.H.V.; NAKANO, E.Y. Inferência bayesiana no modelo weibull discreto em dados com presença de censura. **Tendências em Matemática Aplicada e Computacional**, v. 16, n. 2, p. 97–110, 2015.
- BRUNO, Tatiana Costa et al. Prognosis Related to Reperfusion Therapy Post-Acute Coronary Syndrome in Secondary Care: Long-Term Survival Analysis in the ERICO Study. **Arquivos Brasileiros de Cardiologia**, v. 120, n. 5, p. e20220849, may 2023.

- CANCHO, Vicente G. et al. The destructive negative binomial cure rate model with a latent activation scheme. **Statistical Methodology, Elsevier**, v. 13, p. 48–68, 2013. ISSN 1572-3127. Disponível em: <<https://doi.org/10.1016/j.stamet.2013.01.006>>.
- CANCHO, Vicente G.; RODRIGUES, Josemar; CASTRO, Mário de. A flexible model for survival data with a cure rate: a bayesian approach. **Journal of Applied Statistics**, Taylor & Francis, v. 38, n. 1, p. 57–70, 2011. Disponível em: <<https://doi.org/10.1080/02664760903254052>>.
- CARVALHO, Marília Sá et al. **Análise de sobrevivência: teoria e aplicações em saúde**. Rio de Janeiro, RJ: Editora Fiocruz, 2005.
- CASELLA, George; BERGER, Roger L. **Statistical Inference**. 2nd. ed. Pacific Grove, CA: Duxbury/Thomson Learning, 2002. ISBN 978-0534243128.
- COLLETT, David. **Modelling Survival Data in Medical Research**. 2. ed. Boca Raton, FL: Chapman and Hall/CRC, 2003.
- COLOSIMO, Enrico Antônio; GIOLO, Suely Ruiz. **Análise de Sobrevivência Aplicada**. 1. ed. São Paulo: Editora Blucher, 2006.
- COX, D. R. Regression models and life-tables. **Journal of the Royal Statistical Society. Series B (Methodological)**, v. 34, n. 2, p. 187–220, 1972.
- COX, David R.; OAKES, David. **Analysis of Survival Data**. London: Chapman & Hall, 1984.
- DOBSON, Annette J. **An Introduction to Generalized Linear Models**. 2. ed. Boca Raton: Chapman & Hall/CRC, 2002.
- DUNN, Peter K.; SMYTH, Gordon K. Randomized quantile residuals. **Journal of Computational and Graphical Statistics**, v. 5, n. 3, p. 236–244, 1996.
- FLETCHER, R. A new approach to variable metric algorithms. **The Computer Journal**, v. 13, n. 3, p. 317–322, 1970.
- GOLDFARB, Donald. A family of variable-metric methods derived by variational means. **Mathematics of Computation**, v. 24, n. 109, p. 23–26, 1970.
- KIRKPATRICK, S.; GELATT, C. D.; VECCHI, M. P. Optimization by Simulated Annealing. **Science**, v. 220, n. 4598, p. 671–680, 1983.
- KLEIN, John P.; MOESCHBERGER, Melvin L. **Survival Analysis: Techniques for Censored and Truncated Data**. [S.l.]: Springer, 2003.
- KUTNER, Michael H. et al. **Applied Linear Statistical Models**. 5. ed. Boston: McGraw-Hill/Irwin, 2005.
- LOUZADA, Francisco; CANCHO, Vicente G.; BARRIGA, Gladys D. C. The poisson-exponential regression model under different latent activation schemes. **Computational and Applied Mathematics, SBMAC**, v. 31, n. 3, p. 617–632, 2012. ISSN 0101-8205. Disponível em: <<http://www.scielo.br/cam>>.

- LOUZADA, F. et al. The long-term exponentiated complementary exponential geometric distribution under a latent complementary causes framework. **Tema Tendências em Matemática Aplicada e Computacional**, Sociedade Brasileira de Matemática Aplicada e Computacional, v. 15, n. 1, p. 19–35, 2014. Disponível em: <<http://www.scielo.br/tema>>.
- LYU, Jiahang; NADARAJAH, Saralees. Discrete lognormal distributions with application to insurance data. **International Journal of System Assurance Engineering and Management**, Springer, v. 13, n. 3, p. 1268–1282, 2022. Disponível em: <<https://doi.org/10.1007/s13198-021-01443-x>>.
- MALLER, R. A.; ZHOU, Sean. Testing for the presence of immune or cured individuals in censored survival data. **Biometrics**, International Biometric Society, v. 51, n. 4, p. 1197–1205, December 1995. Disponível em: <<https://doi.org/10.2307/2533253>>.
- MALLER, Ross A.; ZHOU, Xianzheng. **Survival Analysis with Long-Term Survivors**. [S.l.]: Wiley, 1996.
- MCALISTER, Donald. The law of the geometric mean. **Proceedings of the Royal Society of London**, v. 29, n. 198, p. 367–371, 1879. Disponível em: <<http://doi.org/10.1098/rspl.1879.0061>>.
- METROPOLIS, N. et al. Equation of state calculations by fast computing machines. **The Journal of Chemical Physics**, v. 21, n. 6, p. 1087–1092, 1953.
- MOOD, Alexander M.; GRAYBILL, Franklin A.; BOES, Duane C. **Introduction to the Theory of Statistics**. 3rd. ed. New York: McGraw-Hill, 1974. ISBN 978-0070428645.
- NAKAGAWA, T.; OSAKI, S. The discrete weibull distribution. **IEEE Transactions on Reliability**, v. 24, p. 300–301, 1975.
- NAKANO, E.Y.; CARRASCO, C.G. Uma avaliação do uso de um modelo contínuo na análise de dados discretos de sobrevivência. **Trends in Computational and Applied Mathematics**, Sociedade Brasileira de Matemática Aplicada e Computacional, v. 7, n. 1, p. 91–100, 2006.
- OLIVEIRA, M. S. R.; CANCHO, V. G.; LOUZADA, F. Mixture and nonmixture cure fraction models assuming discrete lifetimes: Application to a pelvic sarcoma dataset. **Statistical Methods in Medical Research**, v. 28, n. 9, p. 2652–2665, 2019.
- PAL, Sujit Kumar; BALAKRISHNAN, N. Destructive negative binomial cure rate model and em-based likelihood inference under weibull lifetime. **Statistics & Probability Letters**, v. 116, p. 9–20, 2016.
- PIEGORSCH, Walter W. Maximum likelihood estimation for the negative binomial dispersion parameter. **Biometrics**, [Wiley, International Biometric Society], v. 46, n. 3, p. 863–867, 1990. ISSN 0006341X, 15410420. Disponível em: <<http://www.jstor.org/stable/2532104>>.
- RODRIGUES, Josemar et al. On the unification of long-term survival models. **Statistics & Probability Letters**, v. 79, n. 6, p. 753–759, 2009. ISSN 0167-7152. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167715208005105>>.
- RODRIGUES, Jose et al. Destructive weighted poisson cure rate models. **Lifetime Data Analysis**, Springer, v. 17, n. 3, p. 333–346, 2011.

